

University of Padova

DEPARTMENT OF MATHEMATICS "TULLIO LEVI-CIVITA"

BACHELOR'S DEGREE IN COMPUTER SCIENCE



UNIVERSITÀ
DI PADOVA

Explainable Machine Learning
through Large Language Models:
Analysis and Prompt Design

Bachelor's Thesis

Supervisor

Prof. Michele Scquizzato

Undergraduate

Lorenzo Soligo

ID number 2101057

Dice l'uomo ragno...
— Tullio Vardanega

Dedicato a ...

Abstract

As Machine Learning (ML) models become increasingly prevalent in business applications, ensuring their transparency and reliability through Explainable Artificial Intelligence (XAI) is critical. This project, conducted in collaboration with Zucchetti S.p.A., investigates the interpretability and comprehensibility of various machine learning algorithms.

The research systematically evaluates a spectrum of predictive models, ranging from fundamental regression and classification models—such as Linear Regression, Logistic Regression, Support Vector Machines, and Decision Trees—to complex ensemble methods, including Random Forest, XGBoost, RuleFit, and Symbolic Regression. The analysis explores both intrinsic model transparency and post-hoc explainability techniques, utilizing metrics like SHapley Additive exPlanations (SHAP) to interpret predictions and feature importance. Furthermore, the methodology encompasses the examination of mathematical foundations, internal knowledge representations, and the impact of ensemble techniques on both model performance and explainability. Real-world validation is performed using datasets such as Student Salary Prediction.

A primary objective of this work is bridging the gap between technical accuracy and human-understandable explanations for non-expert stakeholders. To achieve this, the project leverages advanced Prompt Engineering principles. Tailored prompts for Large Language Model (LLM) are developed for each analyzed algorithm. These prompts are explicitly designed to automatically generate human-readable explanations of algorithmic behaviors and predictions. Ultimately, the project delivers production-ready implementations and LLM integration adapters, demonstrating how the synthesis of traditional XAI methodologies with modern language models can significantly enhance the transparency, trust, and responsible deployment of AI systems.

Tieni l'infinito per ciò che lo merita...

— Tullio Vardanega

Acknowledgements

Innanzitutto, vorrei esprimere la mia gratitudine al Prof. Michele Scquizzato relatore della mia tesi, per l'aiuto e il sostegno fornitomi durante la stesura del lavoro.

Desidero ringraziare con affetto i miei genitori per il sostegno, il grande aiuto e per essermi stati vicini in ogni momento durante gli anni di studio.

Ho desiderio di ringraziare poi i miei amici per tutti i bellissimi anni passati insieme e le mille avventure vissute.

Padova, June 2026

Lorenzo Soligo

Contents

1. Introduction	1.
1.1. Company	1.
1.2. Stage idea	1.
1.3. Project goals	2.
1.4. Thesis structure	3.
2. Background knowledge	5.
2.1. Algorithmic analysis structure	5.
2.2. Explainability	5.
2.2.1. Explainability dimensions	6.
2.2.2. Framework di Lipton (2016)	6.
2.2.2.1. 1. Transparency (Trasparenza del Modello)	6.
2.2.2.2. 2. Post-hoc Explainability (Spiegabilità Post-Hoc)	6.
2.2.2.3. Interazione tra le due:	6.
2.2.3. Fattori che Facilitano la Comprensione	7.
2.2.3.1. 1. Semplicità e Brevità	7.
2.2.3.2. 2. Confronto tra Istanze (Contrastive Explanations)	7.
2.2.3.3. 3. Selezione di Cause Determinanti	7.
2.2.3.4. 4. Adattamento al Contesto e all'Audience	7.
2.2.3.5. 5. Gestione di Feature Anomali o Outlier	7.
2.2.3.6. 6. Feature Support (Copertura Applicativa)	7.
2.2.3.7. 7. Causalità vs Correlazione	8.
2.2.4. Applicabilità vs Generalità	8.
2.2.4.1. Non è il Parametro Più Importante	8.
2.3. Prompt Engineering and LLMs	8.
3. ML algorithms analysis	9.
3.1. Analisi preventiva dei rischi	9.
3.2. Requisiti e obiettivi	9.
3.3. Pianificazione	9.
4. Stage description	11.
4.1. Tracciamento dei requisiti	11.
5. Design and code implementation	13.
5.1. Tecnologie e strumenti	13.
5.1.1. Tecnologia 1	13.
5.1.2. Tecnologia 2	13.
5.2. Ciclo di vita del software	13.

5.3. Progettazione	13.
5.4. Design Pattern utilizzati	13.
5.5. Codifica	13.
6. Prompt Engineering	15.
7. Conclusion	17.
7.1. Consuntivo finale	17.
7.2. Raggiungimento degli obiettivi	17.
7.3. Conoscenze acquisite	17.
7.4. Valutazione personale	17.
Bibliography	19.
8. Glossario	21.

List of Figures

Figure 1 Zucchetti S.p.A. logo	1.
--------------------------------------	----

List of Tables

Table 1 Table of the project timeline	2.
Table 2 Table of project goals	3.

Table 3	Tabella del tracciamento dei requisiti funzionali	11.
Table 4	Tabella del tracciamento dei requisiti funzionali	11.
Table 5	Tabella del tracciamento dei requisiti funzionali	11.

Chapter 1.

Introduction

Introduzione al contesto applicativo.

Al momento glossario e citazioni devo ancora capirli.

1.1. Company

Zucchetti S.p.A. is a leading Italian software company specializing in providing comprehensive IT solutions for businesses. Founded in 1978, Zucchetti has grown to become one of the largest software providers in Italy, offering a wide range of products and services that cater to various industries, including manufacturing, retail, healthcare, and public administration.

With a strong focus on innovation and customer satisfaction, Zucchetti is committed to helping organizations optimize their operations and achieve their business goals through cutting-edge technology. Exactly from this commit, the company has been actively involved in the development and implementation of machine learning and artificial intelligence solutions, aiming to enhance the capabilities of their software offerings and provide more value to their clients.



Figure 1: Zucchetti S.p.A. logo

1.2. Stage idea

The internship project is centered around the exploration of Explainable Artificial Intelligence (XAI) techniques, with a specific focus on the interpretability and comprehensibility of machine learning algorithms. The primary objective is to analyze a variety of predictive models, ranging from basic regression and classification algorithms to more complex ensemble methods, in order to evaluate their transparency and explainability. The idea is to increase the understanding

of the results of the models, and to make them more accessible to non-expert stakeholders, by leveraging advanced Prompt Engineering principles to develop tailored prompts for Large Language Models (LLMs) that can automatically generate human-readable explanations of algorithmic behaviors and predictions.

The timeline of the project is structured as follows:

Week	Task
1st	Analysis of Linear Regression, Logistic Regression, Support Vector Machines.
2nd	Analysis of Decision Trees, Random Forests, XGBoost.
3rd	Code implementation and Prompt Engineering for the analyzed algorithms.
4th	Evaluation and documentation of the results.
5th	Analysis of RuleFit and deep dive in Random Forests.
6th	Analysis of Symbolic Regression.
7th	Code implementation and Prompt Engineering for the analyzed algorithms.
8th	Evaluation and documentation of the results, final report writing.

Table 1: Table of the project timeline

1.3. Project goals

The goals follow a notation to distinguish between necessary (N), desirable (D) and optional (O) goals. In the planning phase the goals were defined as follows:

Goal	Description
O-01	Complete and profound comprehension of the choosen algorithms, their mathematical foundations and their internal knowledge representation.
O-02	Comprension of interpretability and explainability techniques in machine learning.
O-03	Comprehension of algorithms design techniques.
O-04	Prompt generation for Large Language Models to generate human-readable explanations.
O-05	Comprehension and application of Prompt Engineering principles in the context of XAI.
D-01	Creation of a metric to evaluate the explainability of the analyzed algorithms.
D-02	Automatization of the analysis pipeline from dataset to LLM requests.
F-01	Application in real-world scenarios of the interpretability and explainability of Machine Learning models.
F-02	Explainability study of semi-supervised and unsupervised algorithms.

Table 2: Table of project goals

1.4. Thesis structure

The second chapter describes the basic concepts that fuel the project. The concepts spread from the mathematical foundations of the analyzed algorithms, the basics of explainability, to the principles of Prompt Engineering and LLMs.

The third chapter analyzes the ML algorithms, focusing on their capability, limitation and interpretability.

The fourth chapter describes the design and implementation of the analysis pipeline from dataset to LLM requests.

The fifth chapter discusses prompt engineering techniques and their application in the context of XAI.

The sixth chapter presents the conclusions of the study, the findings and the goals assessment.

Chapter 2.

Background knowledge

In this chapter, we will provide the necessary background knowledge to understand the project. We will cover the mathematical foundations of the analyzed algorithms, the basics of explainability, and the principles of Prompt Engineering and LLMs.

2.1. Algorithmic analysis structure

The analysis of the algorithms is structured in a systematic way to ensure a comprehensive evaluation of their interpretability and comprehensibility as well as their functioning. The structure includes the following components:

1. **Mathematical foundations:** detailed examination of the mathematical principles underlying each algorithm, including their assumptions, optimization techniques, and theoretical properties.
2. **Computational complexity:** analysis of the computational requirements of each algorithm, including time complexity, space complexity, and scalability regarding both training and inference.
3. **Internal representation:** exploration of how each algorithm internally represents data and makes decisions, especially regarding categorical features.
4. **Data assumptions:** investigation into the assumptions each algorithm makes about the data, such as linearity, independence of features, and distributional assumptions.
5. **Predictive performance and limitations:** evaluation of the predictive performance of each algorithm on relevant datasets, considering the data assumptions and mathematical foundation of the model.
6. **Metrics for prediction quality:** presentation of the most relevant metrics for evaluating the models performance, based on the task.
7. **Metrics for interpretability:** presentation of the most relevant metrics for evaluating the models interpretability, based on the task.
8. **Explainability limitations:** discussion of the limitations of explainability techniques for each algorithm, including potential pitfalls and challenges in interpreting their predictions.

2.2. Explainability

Explainability (or interpretability) of a ML model is the ability to communicate **how and why** the model made a prediction.

Contrary to intuition, explainability it's **not a binary attribute**, but a spectrum with multiple dimensions.

2.2.1. Explainability dimensions

1. Intrinsic Transparency (Model-Level Interpretability)

The model is inherently transparent and interpretable by design. The structure directly communicates how it works, such as regression coefficients or decision tree nodes. Each prediction is fully traceable, and parameters have tangible meanings. Explanations reflect human reasoning, making them coherent from a domain perspective.

It represents the best case scenario for explainability but it is often in trade-off with performance, as more complex models tend to be less transparent but more powerful.

1. Local Interpretability (Instance-Level Explainability)

The model might be opaque and too complex to understand globally. However, for a specific prediction, we can generate an explanation that is locally interpretable. SHAP could be used in this context to explain a particular instance obtained a certain prediction.

2. Interpretabilità dei Parametri

- I parametri del modello hanno un significato tangibile e interpretabile
- Es.: il coefficiente β_j in LR significa "aumentare x_j di 1 causa aumento di y di β_j "
- **Proprietà:** la relazione tra parametri e comportamento è evidente

3. Fedeltà alla Logica Umana

- Le spiegazioni riflettono il ragionamento che un umano avrebbe fatto
- Es.: "il cliente ha defaultato perché: reddito basso (decisione umana plausibile) + punteggio di credito basso"
- **Proprietà:** le spiegazioni suonano coerenti dal punto di vista del dominio

2.2.2. Framework di Lipton (2016)

Il lavoro fondamentale "The Mythos of Model Interpretability" di **Ribeiro et al. (2016)** identifica due categorie ortogonali di spiegabilità:

2.2.2.1. 1. Transparency (Trasparenza del Modello)

Quanto trasparente è il **modello stesso**, indipendentemente dalle predizioni:

- **High:** Linear Regression, Logistic Regression, Decision Trees (piccoli)
- **Medium:** Generalized Additive Models, Ensemble Methods (Random Forests)
- **Low:** Neural Networks, SVM, Gradient Boosting complesso

2.2.2.2. 2. Post-hoc Explainability (Spiegabilità Post-Hoc)

Tecniche applicate **dopo il training** per spiegare previsioni di modelli opachi:

- **SHAP (SHapley Additive exPlanations):** assegna ogni output tra le feature usando valori Shapley dalla teoria dei giochi
- **Feature Importance:** quale feature ha più influenzato la previsione

2.2.2.3. Interazione tra le due:

- Un modello **altamente trasparente** non ha bisogno di post-hoc (spiegazione è diretta)
- Un modello **opaco** usa post-hoc per compensare

- Ideale: trasparenza intrinseca + capacità predittiva

2.2.3. Fattori che Facilitano la Comprensione

Sulla base di ricerca in interpretabilità (Lipton, Molnar, etc.), ci sono **molteplici aspetti** che facilitano la comprensione di una spiegazione:

2.2.3.1. 1. Semplicità e Brevità

- Spiegazioni corte sono preferite a quelle lunghe
- Un numero limitato di cause spieganti (es. 3-5 feature) è più memorizzabile di 10-20
- **Trade-off:** brevità vs completezza; spesso un compromesso è necessario

2.2.3.2. 2. Confronto tra Istanze (Contrastive Explanations)

- "Perché è stata predetta come positiva *questa* istanza rispetto a *quella*?"
- Spiegazione contrastiva è spesso più illuminante che assoluta
- Es.: "il cliente A ha defaultato ma il cliente B no; la differenza principale è il reddito" è più utile che "il cliente A ha reddito basso"
- **Applicazione:** usare nearest neighbors di classe diversa per confronto

2.2.3.3. 3. Selezione di Cause Determinanti

- Non tutte le feature sono uguali; alcune causano la predizione, altre sono correlate ma non causali
- Una spiegazione dovrebbe identificare i **fattori determinanti**, non tutti i fattori

2.2.3.4. 4. Adattamento al Contesto e all'Audience

- La spiegazione deve essere **appropriata al livello di expertise** dell'audience
- Spiegazione a un medico non è la stessa di quella a un paziente
- Spiegazione a un regolatore non è la stessa di quella a un cliente
- **Proprietà:** la qualità di una spiegazione è relativa al contesto

2.2.3.5. 5. Gestione di Feature Anomali o Outlier

- Se una feature ha un valore inusuale, dovrebbe essere segnalato
- Es.: "il cliente ha un'età di 250 anni (anomalia nei dati), quindi la predizione è inaffidabile"
- **Proprietà:** la spiegazione dovrebbe indicare quando il modello è **al di fuori del dominio** di applicazione

2.2.3.6. 6. Feature Support (Copertura Applicativa)

La **generalità** di una previsione può essere quantificata dal **feature support**:

$$\text{Feature Support}_i = \frac{\text{\#istanze nel training con valori simili a } x_i}{\text{\#istanze totali nel training}}$$

Es.: se stiamo predendo per un cliente di 35 anni, e il 70% del training set era tra 30-40 anni, il support è alto (predizione affidabile). Se era il 5%, il support è basso (predizione in zona extrapolazione).

Implicazione: una spiegazione dovrebbe menzionare il support: "questa predizione è affidabile (support = 0.7)" vs "questa predizione è incerta (support = 0.1)"

2.2.3.7. Causalità vs Correlazione

- Una feature può essere **correlata** alla predizione ma non **causale**
- Es.: "il modello predice default perché il cliente è ricco" potrebbe essere spurio se la ricchezza è correlata al credito score, che è il vero driver
- **Proprietà:** la spiegazione ideale identifica la **relazione causale**, non solo quella correlativa
- **Limite:** senza esperimento (es. A/B test), è difficile provare causalità dai dati osservazionali

2.2.4. Applicabilità vs Generalità

2.2.4.1. Non è il Parametro Più Importante

Una spiegazione che è **applicabile a molti casi** (alta copertura) non è necessariamente la **migliore** spiegazione:

- Una spiegazione generale ("tutti i clienti giovani sono rischiosi") ha alta applicabilità ma è imprecisa
- Una spiegazione specifica ("questo cliente è rischioso a causa della combinazione unica di reddito basso + punteggio di credito basso + storia lavorativa instabile") ha bassa applicabilità ma è molto più informativa

Principio: la qualità di una spiegazione non si misura dalla sua generalità, ma dalla sua **utilità nel contesto specifico**.

2.3. Prompt Engineering and LLMs

Chapter 3.

ML algorithms analysis

Breve introduzione al capitolo

3.1. Analisi preventiva dei rischi

Durante la fase di analisi iniziale sono stati individuati alcuni possibili rischi a cui si potrà andare incontro. Si è quindi proceduto a elaborare delle possibili soluzioni per far fronte a tali rischi.

1. Performance del simulatore hardware

Descrizione le performance del simulatore hardware e la comunicazione con questo potrebbero risultare lenti o non abbastanza buoni da causare il fallimento dei test

Soluzione coinvolgimento del responsabile a capo del progetto relativo il simulatore hardware

3.2. Requisiti e obiettivi

3.3. Pianificazione

Chapter 4.

Stage description

In this chapter, we will describe the stage of the internship, starting from the company where the internship took place, the project idea, the requirements and the design of the product, to the testing phase.

4.1. Tracciamento dei requisiti

Da un'attenta analisi dei requisiti e degli use case effettuata sul progetto è stata stilata la tabella che traccia i requisiti in rapporto agli use case.

Sono stati individuati diversi tipi di requisiti e si è quindi fatto utilizzo di un codice identificativo per distinguerli.

Il codice dei requisiti è così strutturato R(F/Q/V)(N/D/O) dove:

R = requisito

F = funzionale

Q = qualitativo

V = di vincolo

N = obbligatorio (necessario)

D = desiderabile

Z = opzionale

Nelle tabelle Table 3, Table 4 e Table 5 sono riassunti i requisiti e il loro tracciamento con gli use case delineati in fase di analisi.

Requisito	Descrizione	Use Case
RFN-1	L'interfaccia permette di configurare il tipo di sonde del test	UC1

Table 3: Tabella del tracciamento dei requisiti funzionali

Requisito	Descrizione	Use Case
RQD-1	Le prestazioni del simulatore hardware deve garantire la giusta esecuzione dei test e non la generazione di falsi negativi	–

Table 4: Tabella del tracciamento dei requisiti funzionali

Requisito	Descrizione	Use Case
RVQ-1	La libreria per l'esecuzione dei test automatici deve essere riutilizzabil	–

Table 5: Tabella del tracciamento dei requisiti funzionali

Chapter 5.

Design and code implementation

Breve introduzione al capitolo

5.1. Tecnologie e strumenti

Di seguito viene data una panoramica delle tecnologie e strumenti utilizzati.

5.1.1. Tecnologia 1

Descrizione Tecnologia 1.

5.1.2. Tecnologia 2

Descrizione Tecnologia 2

5.2. Ciclo di vita del software

5.3. Progettazione

5.4. Design Pattern utilizzati

5.5. Codifica

Chapter 6.

Prompt Engineering

Breve introduzione al capitolo

Chapter 7.

Conclusion

7.1. Consuntivo finale

7.2. Raggiungimento degli obiettivi

7.3. Conoscenze acquisite

7.4. Valutazione personale

Bibliography

- [1] Christoph Molnar, *Interpretable Machine Learning*. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
- [2] Zhen "Leo" Liu, *Artificial Intelligence for Engineers*. Springer.
- [3] a. G. M.-M. Candice Bentéjac Anna Csörgő, "A Comparative Analysis of XGBoost."
- [4] Christopher M. Bishop, *Pattern Recognition and Machine Learning*. Springer.
- [5] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, *An Introduction to Statistical Learning*. Springer.
- [6] V. K. Xidong Wu, *Top 10 Algorithms in Data Mining*. CRC Press.
- [7] Tianqi Chen and Carlos Guestrin, "XGBoost."
- [8] Lior Rokach and Oded Maimon, *Data Mining with Decision Trees*. World Scientific Publishing.

Chapter 8.

Glossario

XAI – Explainable Artificial Intelligence: A field of artificial intelligence that focuses on creating models and systems that can provide clear and understandable explanations for their decisions and actions. i, i

LLM – Large Language Model: A type of artificial intelligence model that is trained on vast amounts of text data to understand and generate human-like language. i

ML – Machine Learning: A subset of artificial intelligence that involves training algorithms to learn patterns from data and make predictions or decisions without being explicitly programmed. i

SHAP – SHapley Additive exPlanations: A method for explaining the output of machine learning models by attributing the prediction to each feature. i